

Izveštaj o analizi skupa podataka o korisnicima mobilnih usluga]

Vuk Radović *

28. septembar 2026.

1 Rezime

2 Podaci i priprema

Podaci s kojima raspolazem opisuju dinamiku korišćenja mobilnih usluga korisnika sva tri tipa paketa. Greške koje sam uočio u toku rada se mogu izraziti tabelarno. Delovi podataka koji se mogu svrstati u neku od ovih klasa su imali tretman zavisno od klase kojoj pripadaju. Tretiranje svake od klasa grešaka je opisano u svakoj od podsekcija dokumenta.

Tabela 1: Rezime identifikovanih problema po klasama

Klasa problema	Broj problema
Nedostajuće vrednosti	252
Nenumeričke vrednosti u numeričkim kolonama	52
Potpuni duplikati	32
Nedosledne kategorije ¹	186
Negativne vrednosti	12
Vrednosti van dozvoljenog opsega ²	6

2.1 Nedostajuće vrednosti

Tretman nedostajućih vrednosti je zavisio od porekla ove pojave. Ipak, ovde je fokus na onim redovima u kojima se to nalazilo bez moje intervencije.

*Praktikant kod Dr Siniše Arsića u periodu od 8.9.2026. do 28.9.2026. Kontakt na vukradovic at hotmail.rs

Tabela 2: Deskriptivna statistika numeričkih promenljivih pre čišćenja

Promenljiva	N	Sred.	Med.	Std.	IQR	CV (%)	Asim.
godine	1184	42.24	42.50	14.93	20.00	35.32	0.86
staz_meseci	1232	41.55	29.00	39.50	42.25	95.04	1.61
mesecni_racun_rsd	1162	3006.55	2381.50	3865.28	2145.25	128.51	10.84
potrosnja_gb	1178	11.74	6.30	60.94	7.08	519.04	15.10
minuti_poziva	1232	279.22	258.50	431.45	183.25	154.46	15.23
broj_sms	1232	38.41	38.00	6.14	9.00	15.99	0.23
broj_reklamacija	1232	0.76	0.00	1.03	1.00	136.15	1.77
ocena_zadovoljstva	1136	3.62	4.00	0.98	1.00	27.13	-0.30

Tabela 3: Deskriptivna statistika numeričkih promenljivih nakon čišćenja

Promenljiva	N	Sred.	Med.	Std.	IQR	CV (%)	Asim.
godine	1191	42.05	43.00	13.11	19.00	31.17	0.15
staz_meseci	1191	41.48	29.00	39.26	42.00	94.61	1.62
mesecni_racun_rsd	1191	2673.32	2361.00	1699.95	2102.50	63.56	1.14
potrosnja_gb	1191	7.74	6.30	6.19	6.80	79.89	2.31
minuti_poziva	1191	256.62	259.00	126.46	180.50	49.26	0.12
broj_sms	1191	38.40	38.00	6.14	9.00	15.98	0.22
broj_reklamacija	1191	0.76	0.00	1.03	1.00	136.29	1.75
ocena_zadovoljstva	1095	3.62	4.00	0.98	1.00	27.10	-0.31

2.2 Rad sa nenumeričkim vrednostima

Problem ove vrste se javljao u poljima koja su iskazivala vrednost mesečnog računa i potrošnju internet saobraćaja.

Originalno, za vrednost mesečnog racuna je predviđeno da se vrednost koja slovima glasi **dve hiljade trista pedeset dinara** iskaže kao 2350. Dakle, unosi kao što su:

- 2.350,00 RSD
- 2350 RSD
- 2.350 din

nikako ne dolaze u obzir. Kako sam uočio odgovarajući obrazac u ovakvim unosima, primenio sam potreban postupak vraćanja ovih unosa u očekivan oblik.

Sličan problem se javlja u polju potrošnje internet saobraćaja, s tim što je predviđeno da se potrošnja iskazuje brojevima bez pisanja obračunske jedinice.

2.3 Potpuni duplikati

Pod ovim se podrazumevaju čitavi redovi koji se ponavljaju. Dakle, primera radi ako na pozicijama 3 i 5 nađemo unose oblika (A,B,C,D) (pri tome da smo pokrili sva polja koje se prate) možemo sumnjati da ovaj red pripada ovoj klasi. Ovo treba razlikovati od redova gde se jedno ili više polja ponavljaju (ali ne sva !). U slučaju ovog skupa, najčešće je slučaj da jedan isti korisnik koristi više mobilnih usluga, a za obe se mora voditi evidencija kao i za ostale korisnike. Prolaskom kroz skup podataka i poređenjem svakog reda u odnosu na očekivanu normu sam otklonio ovaj problem ne dirajući korisnike više usluga.

2.4 Nedosledne kategorije

Nedoslednost u ovom polju se ogleda u problematičnom unosu u sam sistem. Takav podatak ima isto značenje za čoveka bez obzira na sve, ali za postupak obrade podataka to ne važi i sprečava ga da daje tačne podatke. Vrednosti 'Beograd' i 'BEOGRAD' su za čoveka iste, jer imaju isto značenje, ali za obradu podataka su različite jer se u jednom koriste samo velika, a u drugom i mala i velika slova. Takođe, 'Poslovnica ' i 'Poslovnica' nisu isti unosi, jer jedna je bez, a druga sa razmakom.

Kako sam imao precizan uvid u to šta je dopušteno, a šta nije, po svim spornim poljima sam postupno poredio svaki od redova i menjao vrednosti tako da budu u skladu sa očekivanjem.

2.5 Negativne vrednosti i one van dozvoljenih opsega

Mada je moguće zaključiti iz naziva o kakvom problemu se radi, njegov uzrok mi je i dalje nejasan:

- Neko je mogao greškom da unese znak – u predviđeno polje što bi sistem protumačio kao negativnu vrednost,
- Vrednost koja je unesena nije mogla biti pročitana do kraja pravilno u toku postupka obrade
- ili nešto treće što nije moguće oceniti iz ove perspektive.

Trebalo bi napomenuti da sam postupak obrade ovu kategoriju namerno proširuje na sve vrednosti van opsega, jer iako su drugačijeg oblika, zapravo izazivaju iste vrste problema u obradi. Tretman brojčanih polja sa ovim problemima je podrazumevao pretragu u odnosu na očekivane vrednosti i njihovo označavanje markerom za nedostajuću vrednost.

Redove nisam brisao iz razloga što brisanje istih može da izazove gubitak podataka i time izveštaj koji će se generisati neće biti pouzdan. Postupak obrade se nepotrebno komplikuje sa takvom vrstom odlučivanja za koju je upitno može li se pouzdano izraziti logički.

3 Deskriptivna statistika

Tabela 4: Deskriptivna statistika numeričkih promenljivih

Promenljiva	N	Sredina	Medijana	Std. dev.
godine	1191	42.05	43.00	13.11
staz_meseci	1191	41.48	29.00	39.26
mesecni_racun_rsd	1191	2673.32	2361.00	1699.95
potrosnja_gb	1191	7.74	6.30	6.19
minuti_poziva	1191	256.62	259.00	126.46
broj_sms	1191	38.40	38.00	6.14
broj_reklamacija	1191	0.76	0.00	1.03
ocena_zadovoljstva	1095	3.62	4.00	0.98
churn_flag	1191	0.223	0.00	0.42
godina_aktivacije	1185	2022.68	2024.00	3.30
racun_po_gb	1191	660.07	376.39	877.77

Napomena: Promenljiva `churn_flag` je binarno kodirana, pri čemu vrednost 1 označava churn. Sredina od 0.223 odgovara stopi churn-a od približno 22.3%.

Prethodna tebla je prikazivala najvažnije mere kojima se opisuje skup podataka, tj ispitana skupina korisnika.

Napomena: Std. dev je skraćenica od **standardna devijacija** - metrika koja opisuje prosečno odstupanje od aritmetičke sredine ili prosečne vrednosti tog polja.

Treba imati na umu da aritmetička sredina nekada (a ovde izrazito) nije dobar podatak za opis populacije. Odgovarajućim testiranjem ³ je pokazano da većina polja koja se prati ne ispunjava uslove ⁴ da bi mogao preko ovog podatka da opisujem kretanje vrednosti.

Medijana Me je odabrana kao mera za opisivanje populacije zbog toga što je matematički dokazano da bez obzira na to kako su raspoređene vrednosti, ona se uvek nalazi između sredine i modusa ⁵. U našem slučaju, pošto je kretanje veličina takvo da imamo nagli skok koji je praćen postupnim opadanjem (tzv. desna asimetričnost u odnosu na sredinu), važi da je prosek nešto veći od medijane. Ta razlika je u ovom slučaju prihvatljivo velika i ne utiče na preciznost, a pokazuje praktično istu stvar kao prosečna vrednost tamo gde ona zaista sme da se koristi. Za primer pogledati sliku 3

4 Nalazi

Poslovni interes je zadržati što je moguće više korisnika. Od ukupno 1191 ispitanih korisnika ⁶ curenja se uočavaju:

4.1 Povezanost odlaska sa ostalim poljima


Pogledati sliku 3 kako bi se videla jačina povezanosti odlazaka sa drugim veličinama.

³Primenjen je Shapiro-Wilkov test za normalnost raspodele. Mogao je biti korišćen i Kolmogorov-Smirnovljev test i na ovaj broj operacija bi davali isti zaključak, ali zbog preciznosti i brzine rada je on izbegnut.

⁴U statistici, prosečna vrednost je merilo populacije onda i samo onda kad veličina podleže tzv normalnoj raspodeli. Njena osobina je da se tada najveći deo vrednosti koje imamo gomila upravo oko te prosečne i da se odstupanja velike većine tih vrednosti od proseka smatraju zanemarljivim. Takođe, tačka u kojoj je prosečna vrednost deli sam uzorak na dve jednake polovine tj. čini raspodelu simetričnom. Sve što od odstupa od toga daje raspodelu koja je asimetrična.

⁵Najčešća vrednost koja se javlja


⁶Nad ovima je tehnički izvodljivo ispitivanje !




Slika 1: Prosečan mesečni račun tipičnog korisnika

Tabela 5: Grupe sa najvišim stopama churn-a

Kategorija	Grupa	Stopa odlaska (%)
Pol	Ž	23.06
Tip paketa	Prepaid	29.56
Kanal prodaje	Partner	24.46
Starosna grupa	30–44	24.95
Stož	< 1 god.	32.57



Slika 2: Odlazak korisnika nakon godinu dana po segmentima



Slika 3: Korelaciona matrica odlaska i drugih veličina

4.2 Neka istraživačka pitanja

4.2.1 Da li korisnici odlaze zbog nekog kanala prodaje ?

Na osnovu raspoloživih 1191 upisa, verovatnoća da je ovo zaista realan trend je **manji od 1%** što kazuje da apsolutno ne postoji nikakav prostor za sumnju ovog tipa (videti sliku 4)

Napomena: Vrednost 1 označava odlazak !

4.2.2 Postoje li obrasci korišćenja sadržaja paketa prema starosnoj grupi ?

Tabela 6: Rezultati testa razlika između starosnih grupa


Promenljiva	H statistika	Verovatnoća slučajnosti	Zaključak
Potrošnja interneta	478.490	2.19×10^{-103}	Statistički značajna razlika
Slanje poruka	2.105	0.551	Nije statistički značajno
Minuti poziva	6.007	0.111	Nije statistički značajno

Definitivno vidimo da je potrošnja interneta zaista različita prema pripadnosti starosnoj grupi, dok su ostale veličine prilično uravnotežene. Naknadne analize su pokazale da je priča preko telefona i slanje poruka prilično uravnotežene među grupama.


Zbog praktičnosti u izveštavanju, uzeću grupaciju od 18-29 jer imam najviše njenih pripadnika, ali račun pokazuje isti obrazac i na drugim. Na slici 5 se vidi kretanje potrošnje interneta u odnosu na normalnu raspodelu. Vidi se da bez obzira na neuklapanje u nju, ona pokazuje prilično stabilan obrazac.

4.2.3 Preferiraju li se neki paketi u nekim kanalima prodaje ?


Testiranje je ukazalo da je verovatnoća preferiranja nekog paketa u nekom kanalu prodaje **manja od 1%**. Prema tome, nema prostora ni za kakvu sumnju u ovom pogledu, što pokazuje grafik 6



Slika 4: Odnos odlaska i kanala prodaje




Slika 5: Kretanje potrošnje interneta grupacije 18-29 u odnosu na normalnu raspodelu




Slika 6: Kretanje potrošnje interneta grupacije 18-29 u odnosu na normalnu raspodelu

5 Prikazi važnijih kretanja


U nastavku će biti prikazana kretanja važnijih veličina za potrebe analiziranja ovog segmenta tržišta.



Slika 7: Odlazak korisnika po stažu provedenom u TS (desno) i po tipu paketa (levo)



Slika 8: Odlazak korisnika po stažu broju reklamacija (desno) i po oceni zadovoljstva (levo)



Slika 9: Odlazak korisnika po stažu broju reklamacija (desno) i po oceni zadovoljstva (levo)

6 Nalazi i ograničenja